

山东大学 计算机科学与技术 学院

大数据分析实践 课程实验报告

学号：202300271038	姓名：李云飞	班级：数据 23
实验题目：		
实验学时：2	实验日期：2025/09/15	
实验目的：利用 Pandas 库实现多种数据采样和过滤的方法		
硬件环境： 计算机一台		
软件环境： python3.9, jupyter notebook		
实验步骤与内容： 本实验在 Python3.9 和 Jupyter Notebook 环境下开展，首先导入 pandas、numpy 库，读取指定地址的 data.csv 数据集，发现数据底部存在大量空行；随后使用 dropna (how='any') 方法删除所有包含空值的行完成数据清洗，再通过 loc 索引依次过滤出 traffic 列值不等于 0 且 from_level 列为 “一般节点” 的数据集；基于清洗过滤后的数据集，进一步实施多种采样操作：为 to_level 列的 “一般节点” 和 “网络核心” 分别设置 1:5 的权重，采用 sample 方法抽取 50 个样本完成加权采样；直接调用 sample 方法随机抽取 50 个样本完成随机采样；按 to_level 列分层，分别从 “一般节点” 中抽取 17 个样本、“网络核心” 中抽取 33 个样本，再通过 concat 拼接完成分层采样，同时可自行拓展实现系统抽样、整群抽样等其他采样方法。		
结论分析与体会： 本次实验通过 Pandas 库成功实现了数据预处理与多种数据采样方法，不同采样方式呈现出差异化特征：随机采样具备无偏性，能反映数据集整体特征，但结果随机性较强；加权采样因赋予 “网络核心” 更高权重，样本结果明显偏向该类别，适用于需突出特定类别重要性的分析场景；分层采样严格遵循 to_level 类别比例抽取样本，有效规避了抽样偏差，保障了各类别在样本中的占比与原数据集一致。实验过程中深刻认识到数据预处理是后续采样有效的基础，删除空行、精准过滤能避免无效数据干扰采样结果；Pandas 的 loc 索引、sample 方法等功能高效且灵活，可快速适配多样的采样需求，同时也体会到采样方法的选择需贴合分析目标，只有结合业务场景选择合适的采样方式，才能让样本数据准确反映数据集的核心特征，为后续数据分析提供可靠支撑。		