

山东大学 计算机科学与技术 学院

大数据分析实践 课程实验报告

学号：202300271038	姓名：李云飞	班级：数据 23
实验题目：数据质量实践		
实验学时：2	实验日期：2025/10/15	
实验目的：本次实验主要围绕宝可梦数据集进行分析，考察在拿到数据后如何对现有的数据进行预处理清洗操作，建立起对于脏数据、缺失数据等异常情况的一套完整流程的认识。		
硬件环境： 计算机一台		
软件环境： python3.9, jupyter notebook		
实验步骤与内容： 本实验在 Python3.9 和 Jupyter Notebook 环境下开展，以包含 721 条宝可梦信息（涵盖编号、名称、双属性、HP/Attack 等基础属性、generation 和 Legendary 等特征）的 Pokemon.csv 数据集为对象，围绕数据质量预处理清洗展开操作：首先读取数据集并整体检视数据特征与异常表现，随后针对性处理各类数据问题：直接删除数据集最后两行无意义的无效数据；识别 type2 列的异常数值取值并清空该部分异常内容；检测数据集中的重复值并采用合适方式（如 drop_duplicates 方法）去除；通过统计分析（如四分位数、Z-score 等）识别 Attack 属性中的过高异常值，并根据分析需求选择剔除或修正该类异常值；定位到两条 generation 与 Legendary 属性被错误置换的数据，核对真实逻辑后修正这两个字段的取值，完整完成宝可梦数据集的脏数据、异常数据预处理流程。		
结论分析与体会： 本次实验完成了多类数据质量问题的预处理清洗，不同类型的脏数据需匹配针对性的处理策略：无意义行直接删除可快速剔除无效信息，重复值处理能避免数据冗余对分析结果的干扰，type2 异常值清空可统一字段取值规则，Attack 过高异常值处理能规避极端值对属性分析的偏差，而修正置换的 generation 与 Legendary 属性则还原了数据的真实特征。实验过程中深刻认识到数据预处理并非单一操作，而是需先全面识别脏数据、异常数据类型，再按“识别 - 定位 - 处理 - 验证”的完整流程操作；宝可梦数据集的各类异常也反映出实际数据中脏数据的多样性，建立标准化的异常处理流程是保障数据质量的核心，同时体会到预处理后的干净数据是后续数据分析、建模的基础，忽视任何一类数据异常都可能导致分析结果失真，也进一步理解了数据质量把控在整个数据工作流程中的关键地位。		