

山东大学 计算机科学与技术 学院

大数据分析实践 课程实验报告

学号：202300271038	姓名：李云飞	班级：数据 23
实验题目：BERT 实践		
实验学时：2	实验日期：2025/11/15	
实验目的：对动手实践利用机器学习方法分析大规模数据有进一步了解，并学习如何利用远程环境进行工程代码的调试.		
硬件环境： 计算机一台		
软件环境： torch==1.7.0 transformers==4.18.0		
实验步骤与内容： 构建基于颜色名称生成对应 RGB 值的回归模型：首先完成远程服务器环境配置，通过 SSH 工具（如 XShell）连接服务器，下载 Linux 版 Anaconda 安装包并经 FTP 传输至指定位置，执行 bash 命令完成安装，随后用 conda create 创建独立于 base 的虚拟环境，激活环境后安装 torch==1.7.0、transformers==4.18.0 等依赖包；接着配置 PyCharm，打开已有代码项目后，依次完成 SSH configuration 配置（建立与服务器的连接）、deployment 路径映射设置、Python Interpreter 指定（关联已配置的 deployment），开启 deployment 自动同步并手动上传初始代码；最后基于 PyTorch 框架实践颜色名 - RGB 数据集的回归任务：载入自定义的颜色名 RGB 数据集（包含各类自然语言颜色名称如“天蓝色”“玫瑰红”“暗紫色”等，及对应标准化 / 原始取值的 RGB 三元组标注数据）并构建批次大小为 16、开启数据打乱的 DataLoader，配置 CUDA/CPU 运行设备，加载 HuggingFace 的 BERT-base-uncased（或适配中文的 BERT 预训练模型）及分词器并部署至指定设备，初始化自定义全连接 FCModel（输出维度为 3，对应 RGB 三个通道值）并部署至设备；定义 Adam 优化器（分别优化 FCModel 和 BERT 模型参数，学习率均为 0.001）与 MSE 损失函数（适配 RGB 连续值回归任务），编写 MAE（平均绝对误差）函数量化预测值与真实 RGB 值的偏差，实现 train 训练函数（按批次读取颜色名称数据，经分词器编码后输入 BERT 得到 pooler_output 语义表征，传入 FCModel 输出 RGB 预测值，计算 MSE 损失与 MAE 指标，通过反向传播更新模型参数，统计批次和 epoch 级别的损失、MAE），设置 1 个训练轮次并执行训练，全程梳理颜色名文本预处理、模型读入、RGB 值推理及回归效果评价的完整逻辑。		
结论分析与体会： 本次实验完成了远程 GPU 服务器环境配置、PyCharm 远程开发调试适配，以及基于 BERT 微调实现颜色名称生成 RGB 值回归模型的全流程实践，清晰展现了文本到连续数值生成任务中机器学习方法的选择与应用逻辑。从实验结果来看，远程 GPU 服务器的算力支撑了 BERT 预训练模型处理颜色名文本的高效运行，分批次训练模式兼顾了显存占用与训练效率，MSE 损失函数精准适配 RGB 连续值的回归损失计算需求，MAE 指标则能直观量化预测 RGB 值与真实值的偏差程度。实验过程中深刻认识到，远程环境配置是大规模机器学习		

习任务落地的基础: Anaconda 虚拟环境有效隔离了依赖包版本, 避免环境冲突; PyCharm 的 SSH 和 deployment 配置实现了本地代码与远程服务器的实时同步及调试, 大幅降低了远程开发的门槛。同时也理解到, 机器学习方法的选择需紧密贴合任务场景 —— 针对颜色名生成 RGB 的回归任务, 选择 BERT 预训练模型能充分捕捉颜色名的语义特征 (如 “浅红” 与 “深红”、“湖蓝” 与 “藏蓝” 的语义差异), 相较于传统文本特征提取方法 (如 TF-IDF) 更能挖掘颜色名的深层语义关联, 而 “预训练文本模型 + 全连接回归层” 的模式则高效实现了从文本语义表征到 RGB 数值的映射; 优化器、损失函数的选择也需匹配任务类型, Adam 优化器的自适应学习率特性提升了模型收敛效率, MSE 则适配连续值回归的损失计算逻辑, MAE 相比 MSE 更能直观反映 RGB 值的实际偏差 (符合视觉感知层面的误差判断)。此外, 实验中关注显存占用 (如 `torch.cuda.memory_allocated()`) 的细节, 也让我体会到工程调试中参数优化 (如批次大小、分词长度) 对训练稳定性的重要性, 而颜色名语义的完整性 (如覆盖更多小众颜色名称) 对模型泛化能力的影响, 也为后续优化模型效果 (如扩充数据集、调整 BERT 模型层级) 提供了明确方向。